

Um Sistema Hardware/Software para Detecção de Obstáculos em Vias Urbanas

**Alicia R. dos Santos¹, Julia S. Barreiros¹, João V. S. da Silva¹,
Amanda B. Ferreira¹, Richard J. M. G. Tello¹**

¹Instituto Federal do Espírito Santo (IFES) - Campus Serra
Av. dos Sabiás, 330 - Morada de Laranjeiras, Serra - ES - Brasil

{allicia30300, julia.barreiros16, silveiraxdx}@gmail.com,
amandabalestreiro4@gmail.com, richard@ifes.edu.br

Abstract. *This paper presents the development of an embedded hardware and software system for obstacle detection on roads. The system consists of a 4WD mobile robot equipped with an ESP32 board and an MPU6050 inertial sensor. Scaled obstacles, produced by 3D printing, were tested in linear and rectangular scenarios. The data collected by the inertial sensor were transmitted via Wi-Fi for external processing. After preprocessing and segmentation of the temporal signals, recurrent neural networks (LSTM, Bi-LSTM, and GRU) were employed for analysis. The results indicated that the GRU network achieved the best performance, reaching an average accuracy above 98% in both evaluated scenarios. These findings demonstrate the feasibility of the system for identifying irregularities in controlled environments.*

Resumo. *Este artigo apresenta o desenvolvimento de um sistema embarcado de hardware e software para detecção de obstáculos em vias. O sistema é composto por um robô móvel 4WD equipado com uma placa ESP32 e um sensor inercial MPU6050. Obstáculos em escala, produzidos por impressão 3D, foram testados em cenários lineares e retangulares. Os dados coletados pelo sensor inercial foram transmitidos via Wi-Fi para processamento externo. Após o pré-processamento e a segmentação dos sinais temporais, redes neurais recorrentes (LSTM, Bi-LSTM e GRU) foram empregadas para análise. Os resultados indicaram que a rede GRU apresentou o melhor desempenho, alcançando acurácia média superior a 98% nos dois cenários avaliados. Esses achados demonstram a viabilidade do sistema para a identificação de irregularidades em ambientes controlados.*

1. Introdução

A infraestrutura viária e as melhorias no trânsito desempenham um papel essencial no desenvolvimento e no funcionamento das áreas urbanas no Brasil, ao facilitarem a mobilidade da população brasileira e o transporte de mercadorias no país, contribuindo para o crescimento urbano e para a melhoria da qualidade de vida nas cidades. O fluxo contínuo de veículos, somado às condições ambientais adversas, provoca a deterioração do revestimento asfáltico, resultando na formação de irregularidades como buracos, colocando em risco a segurança de pedestres e motoristas, além de aumentar os custos de manutenção das vias e dos veículos.

No Brasil, cerca de 66,9% das rodovias brasileiras apresentam algum tipo de problema no pavimento, afetando diretamente a segurança viária e desempenho logístico do país, além de aumentar em até 32,5% os custos operacionais dos veículos [Confederação Nacional do Transporte 2024]. Dessa forma, o desenvolvimento de tecnologias capazes de identificar essas anomalias para auxiliar na conservação das estradas torna-se crucial.

Nas últimas décadas, a indústria automobilística tem incorporado uma grande quantidade de sensores e chips em seus veículos. Em 2018, a revista Quatro Rodas destacou que a quantidade de sensores embarcados cresceu significativamente nas últimas décadas, enquanto na década de 1990 um carro popular contava com cerca de 10 sensores, no ano de 2010 esse número chegava a aproximadamente 30, e, nos modelos mais sofisticados em 2018, ultrapassava a 100 sensores [Rodas 2018].

Nesse contexto, dispositivos embarcados de baixo custo e com consumo de energia otimizado, como a plataforma ESP32 e sua integração com sensores inerciais, possibilitam a coleta constante de dados em diversas aplicações. Este trabalho adotou esta plataforma e dispositivos com o intuito de identificar anomalias ou obstáculos presentes numa via. Pesquisas, incluindo as descobertas de [Mednis et al. 2011], destacam a eficácia da utilização de acelerômetros na detecção de anomalias nas estradas, proporcionando resultados com elevada precisão em ambientes de pesquisas.

Além de apoiar a manutenção viária, essas informações podem ser utilizadas de forma automatizada por aplicações de cidades inteligentes, como sistemas de navegação e monitoramento constante urbano. Os dados sobre o estado da via e/ou a presença de obstáculos podem ser incorporados a aplicativos de GPS para otimizar rotas e alertar motoristas, além de possibilitar a integração dessas informações com órgãos governamentais ou empresas interessadas em soluções logísticas e de mobilidade.

Este trabalho apresenta o desenvolvimento de um sistema de hardware e software voltado à identificação de diferentes tipos de obstáculos, como buracos, quebra-molas, lombos e tachões, contribuindo para a aceleração do processo de manutenção viária. A detecção foi realizada por meio de um protótipo robótico equipado com um ESP32 e um módulo MPU6050, que percorreu dois cenários experimentais contendo tais obstáculos. A base de dados analisada foi construída a partir das medições de aceleração e rotação angular coletadas durante os trajetos, processadas na própria plataforma ESP32 e transmitidas via Wi-Fi para um computador.

2. Referencial Teórico e Trabalhos Correlatos

As literaturas a seguir foram previamente avaliadas com base em artigos selecionados e publicados nos últimos anos:

No trabalho de [Ye et al. 2024], foi desenvolvido um sistema distribuído de monitoramento inteligente de pavimentos, autoalimentado e baseado em Internet das Coisas (IoT), que integra sensores, uma plataforma em nuvem, rede de comunicação e sistema de fornecimento de energia. Os testes foram realizados em um ambiente urbano utilizando uma série de sensores capazes de detectar anomalias na superfície por meio de padrões de vibrações. Para isso, foram empregados múltiplos sensores embarcados em uma plataforma IoT, como o ESP32 equipado com câmera, GPS e acelerômetro, fornecendo um

modelo eficaz para o gerenciamento de diversos fluxos de dados em ambientes rodoviários desafiadores, onde o monitoramento em tempo real é essencial para garantir a segurança e a manutenção das vias.

No estudo de [Rosca et al. 2025], foi desenvolvida uma solução de otimização do tráfego com dispositivos de baixo custo, empregando um ESP32 integrado a sensores inerciais e câmeras para coletar dados em tempo real das vias. A detecção de buracos baseou-se em um limite de 0,8 rad/s, e serviços de inteligência artificial em nuvem reforçaram a segurança e o monitoramento. A partir dos dados, calculou-se o Global Route Quality Indicator (GRQIk), que avalia rotas considerando distância, atrasos, tempo de viagem, segurança viária e sensibilidade do usuário. Os resultados demonstraram a eficácia do GRQIk na classificação da qualidade das rotas, comprovando a viabilidade de sistemas inteligentes de transporte com sensoramento embarcado e análise em nuvem.

Na pesquisa de [Zareei et al. 2025], foi apresentada uma abordagem de aprendizado de máquina baseada em vibrações para o monitoramento de condições viárias no México. Com o objetivo de acelerar o processo de mapeamento de anomalias, os autores analisaram dados de acelerômetro e giroscópio coletados por smartphones Android. A metodologia adotada inclui um aplicativo móvel para a coleta de dados, extração de características e classificação de amostras, além da aplicação de uma filtragem por média móvel. Os resultados experimentais demonstraram 98% de precisão na distinção entre buracos e lombadas, utilizando dados de seis sensores. Os autores também destacam que o baixo custo de implementação, aliado à alta acurácia do sistema, torna a solução promissora para o monitoramento de condições rodoviárias em larga escala.

Os sistemas desenvolvidos BusNet [De Zoysa et al. 2007] e Pothole Patrol [Eriksson et al. 2008] detectam anomalias viárias utilizando veículos em circulação como plataformas de sensoramento. No BusNet, acelerômetros triaxiais foram acoplados a ônibus públicos em Colombo, coletando dados de aceleração e GPS de forma tolerante a atrasos, sem métricas formais de acurácia, mas com baixo custo e boa cobertura urbana. De forma semelhante, o Pothole Patrol equipou táxis em Boston com acelerômetros de três eixos e GPS, coletando mais de 2.400 km de dados, com um algoritmo de detecção em cinco estágios que reduziu falsos positivos para menos de 0,2% e obteve mais de 90% de precisão na identificação de buracos. Ambos os projetos reforçam o potencial do uso de sensores embarcados e dados de aceleração para o monitoramento de vias urbanas, abordagem que também fundamenta o presente trabalho.

As referências consultadas reforçam a relevância do tema, evidenciando que o desenvolvimento de tecnologias para detecção de anomalias pode contribuir significativamente para a manutenção de uma estrutura viária mais segura e adequada.

3. Materiais e Métodos

3.1. Dispositivos Embarcados e Aquisição de Dados

Inicialmente, foram selecionados os dispositivos embarcados mais adequados após uma análise comparativa das opções disponíveis no mercado, considerando critérios como baixo custo, baixo consumo de energia, comunicação sem fio e capacidade de processamento. Dessa forma, a placa ESP32 e o módulo MPU6050 foram escolhidos como os mais indicados para o projeto.

O ESP32 é uma plataforma de prototipagem com Wi-Fi e Bluetooth integrados, projetada para aplicações de Internet das Coisas (IoT) e automação. Foi adotado o modelo de 30 pinos, que disponibiliza 25 portas GPIO compatíveis com funções de PWM, I2C e SPI. Possui ainda 4 MB de memória flash, 520 KB de memória RAM, e dois núcleos de processamento Tensilica Xtensa LX6. O módulo MPU6050, por sua vez, é um dispositivo eletrônico que possui, em um único chip, um acelerômetro e um giroscópio de 3 eixos, além de um sensor de temperatura.

Esses dois dispositivos foram integrados a um robô móvel (Figura 1(f)) com chassi de quatro rodas motrizes (4WD), o qual serviu como plataforma experimental para a coleta de dados. O controle do robô foi realizado manualmente via teclado de um computador conectado ao ESP32 por Wi-Fi, permitindo que o operador conduzisse o robô sobre os obstáculos em diferentes testes. Os testes foram realizados em ambiente controlado, com piso regular de concreto, e os dados de aceleração e rotação foram coletados em tempo real a partir do MPU6050, com taxa de amostragem de 10 Hz, armazenados para posterior análise e classificação dos diferentes tipos de obstáculos detectados (ver Figura 1).




Figura 1. Obstáculos impressos em 3D (PLA) e robô móvel 4WD montado para os testes.

Após a definição dos dispositivos utilizados no projeto, iniciou-se a construção dos protótipos representativos de cada tipo de obstáculo considerado: lombofaixa (Figura 1(a)), quebra-molas (Figura 1(b)), buraco A (Figura 1(c)), buraco B (Figura 1(d)) e tachões (Figura 1(e)). Adicionalmente, incluiu-se a classe “Normal”, correspondente aos trechos do percurso sem a presença de impedimentos. Os protótipos foram confeccionados por meio de impressão 3D utilizando PLA (ácido polilático) e posteriormente pintados com tinta acrílica em spray, seguindo as especificações técnicas estabelecidas pelo Departamento Estadual de Trânsito (DETRAN).

3.2. Coleta de dados

Após a confecção dos obstáculos em impressão 3D com PLA e a montagem do robô móvel 4WD, o ambiente experimental foi preparado para a etapa de coleta de dados. Nessa fase, os dados inerciais (aceleração e velocidade angular) foram obtidos por meio do sensor MPU6050, conectado à placa ESP32. Esta foi responsável pela aquisição das leituras e pelo envio das informações via Wi-Fi para armazenamento e posterior análise.

O robô é controlado e monitorado por uma interface web hospedada no ESP32 via ESPAsyncWebServer. Conectado à rede Wi-Fi através de um roteador como intermediário, o dispositivo fornece um endereço IP para acesso pelo navegador no computador, permitindo o envio de comandos de movimento e recepção dos dados inerciais do MPU6050 para sua visualização por meio de *Server-Sent Events* (SSE). Os comandos acionam diretamente os pinos de controle dos motores, enquanto as leituras são processadas e transmitidas pelo próprio microcontrolador (ver Figura 2).




Figura 2. Componentes do sistema.

A coleta foi realizada a uma taxa de amostragem de 10 Hz, resultando em 10 amostras por segundo. Cada amostra continha os componentes de aceleração e velocidade angular nos três eixos, totalizando seis variáveis por registro. O processo foi dividido em três subetapas. Na primeira, foram realizados testes individuais para cada obstáculo, posicionando apenas um elemento no percurso do robô por vez. Para cada tipo de obstáculo, foram coletados 30 arquivos de dados, gerando um conjunto específico de medições que caracterizam o padrão de detecção de cada um.

Nas subetapas seguintes, foram coletados os dados para a realização dos Experimentos 1 e 2. No Experimento 1, os obstáculos foram distribuídos em linha reta, conforme ilustrado na Figura 3. Já no Experimento 2, os obstáculos foram distribuídos ao longo de um circuito retangular de dimensões 160 cm × 72,2 cm, conforme ilustrado na Figura 4. Todos os registros foram salvos em arquivos no formato .csv, sendo posteriormente organizados e classificados conforme a categoria do evento identificado.

3.3. Pré-processamento e Segmentação dos Dados

Ao concluir a etapa de coleta de dados, iniciou-se o processo de pré-processamento e segmentação dos dados brutos coletados. O processo de pré-processamento iniciou-se com a rotulação dos dados brutos, que foi realizada manualmente analisando o padrão




Figura 3. Trajeto percorrido pelo robô móvel realizado em linha reta durante o Experimento 1.




Figura 4. Trajeto percorrido pelo robô móvel em um percurso retangular durante o Experimento 2.

comportamental de cada obstáculo. Em seguida, os dados foram segmentados em janelas de tempo fixo. Os dados registrados em cada percurso foram divididos em janelas de 2 segundos, correspondentes a 20 amostras.

Após a segmentação, os dados foram normalizados. Para isso, os dados foram padronizados utilizando o método *StandardScaler*, da biblioteca *scikit-learn*. O escalonador foi ajustado exclusivamente sobre os dados de treino dos obstáculos puros do primeiro *fold* e, posteriormente, aplicado aos dados de treino, validação e teste de todos os *folds*, a fim de manter a consistência na escala dos dados.

3.4. Modelos de Aprendizagem de Máquina

Com o conjunto de dados tratado e padronizado, iniciou-se a fase de modelagem, na qual foram comparados três modelos de Redes Neurais Recorrentes (RNNs) para detecção de obstáculos: LSTM (*Long Short-Term Memory*), Bi-LSTM (*Bidirectional LSTM*) e GRU (*Gated Recurrent Unit*). Essas arquiteturas, amplamente usadas em séries temporais, superam a limitação de dependência de longo prazo das RNNs tradicionais. A LSTM utiliza células de memória para capturar relações temporais complexas [Hochreiter and Schmidhuber 1997]; a Bi-LSTM processa a sequência em ambas as direções, passado e futuro [Schuster and Paliwal 1997]; e a GRU simplifica a LSTM com menos portas, preservando a capacidade de aprendizado com menor custo computacional e, em muitos casos, desempenho superior [Cho et al. 2014].

Os três modelos foram configurados com três camadas (150, 150 e 100 unidades), utilizando a função de ativação **ReLU** nas camadas intermediárias e **Softmax** na saída. A técnica de regularização **Dropout** com taxa de 0.3 foi aplicada. Para o treinamento, foram utilizados a função de perda `sparse_categorical_crossentropy` e o otimizador **Adam** (com taxa de aprendizado de 1×10^{-5}).

A avaliação dos modelos nos Experimentos 1 e 2 seguiu o método de **validação cruzada K-Fold estratificada** ($K = 5$), utilizando a biblioteca `StratifiedKFold` do `scikit-learn`. Em cada iteração, 20% dos dados foram reservados para teste, enquanto os 80% restantes foram divididos em treino (64%) e validação (16%). Cada modelo foi treinado por até 200 épocas, com um *batch size* de 32 e **Early Stopping** (paciência=30) para evitar o sobreajuste.

4. Resultados e discussão

4.1. Experimento 1

A Tabela 1 mostra os resultados do Experimento 1, evidenciando que o GRU obteve o melhor desempenho entre os modelos avaliados. A acurácia média do GRU foi de 98,61%, superior aos 98,21% do LSTM e aos 97,98% do Bi-LSTM. Além disso, o GRU apresentou o menor *loss* médio (0,0467) e o maior F1-score médio (0,988), indicando uma classificação mais precisa e consistente das seis classes avaliadas.

Tabela 1. Comparativo de Desempenho dos Modelos de RNN - Experimento 1

Arquitetura	Acurácia Média $\pm$ Desvio Padrão (%)	Loss Médio	F1-score Médio
LSTM	98,21 $\pm$ 0,0069	0,0566	0,984
Bi-LSTM	97,98 $\pm$ 0,0050	0,0675	0,980
GRU	98,61 $\pm$ 0,0036	0,0467	0,988

A Tabela 2 demonstra que o LSTM obteve um desempenho quase perfeito em todas as classes, com valores na diagonal principal da matriz de confusão acima de 98%, demonstrando a alta eficácia do modelo em classificar corretamente cada classe.

Tabela 2. Matriz de Confusão Normalizada LSTM - Experimento 1

Previsto \ Real	Quebra-molas	Buraco A	Buraco B	Lombofaixa	Tachões	Normal
Quebra-molas	0,99	0,00	0,00	0,00	0,00	0,01
Buraco A	0,00	0,99	0,00	0,00	0,00	0,01
Buraco B	0,00	0,01	0,98	0,00	0,00	0,01
Lombofaixa	0,00	0,01	0,00	0,99	0,00	0,00
Tachões	0,00	0,00	0,00	0,01	0,99	0,00
Normal	0,00	0,00	0,00	0,00	0,00	1,00

Em seguida, a Tabela 3, revela que o Bi-LSTM, também teve bom desempenho (acima de 92%), mas apresentou algumas confusões, como classificar 6% dos “Buraco A” como “Buraco B” e 3% dos “Buraco B” como “Buraco A”, o que pode ser atribuído à similaridade dos dados temporais desses obstáculos.

Por fim, a Tabela 4 mostra que o GRU obteve um desempenho destacável, com acurácia na diagonal principal da matriz próxima de 99% para todas as classes. O modelo apresentou quase nenhuma confusão entre as classes e classificou a classe “Normal” com precisão máxima, evidenciando uma alta capacidade de distinguir os diferentes tipos de obstáculos.

Tabela 3. Matriz de Confusão Normalizada Bi-LSTM - Experimento 1

Previsto \ Real	Quebra-molas	Buraco A	Buraco B	Lombofaixa	Tachões	Normal
Quebra-molas	0,98	0,00	0,00	0,00	0,00	0,01
Buraco A	0,00	0,92	0,06	0,00	0,00	0,02
Buraco B	0,00	0,03	0,96	0,00	0,00	0,01
Lombofaixa	0,01	0,00	0,00	0,97	0,02	0,00
Tachões	0,00	0,00	0,00	0,00	1,00	0,00
Normal	0,00	0,00	0,00	0,00	0,00	1,00

Tabela 4. Matriz de Confusão Normalizada GRU - Experimento 1

Previsto \ Real	Quebra-molas	Buraco A	Buraco B	Lombofaixa	Tachões	Normal
Quebra-molas	0,99	0,00	0,00	0,01	0,00	0,01
Buraco A	0,00	0,99	0,00	0,00	0,00	0,01
Buraco B	0,00	0,01	0,99	0,00	0,00	0,01
Lombofaixa	0,00	0,00	0,00	1,00	0,00	0,00
Tachões	0,00	0,00	0,00	0,00	1,00	0,00
Normal	0,00	0,00	0,00	0,00	0,00	1,00

4.2. Experimento 2

A Tabela 5 exibe os resultados do Experimento 2, evidenciando que a LSTM e a GRU obtiveram desempenhos superiores a Bi-LSTM. A GRU apresentou a maior acurácia média (99,25%), acompanhada com o menor desvio padrão registrado (0,0030) e do menor *loss* médio (0,0475), além de igualar a LSTM no F1-score (0,990). A LSTM, por sua vez, alcançou 98,92% de acurácia média, com baixo desvio padrão (0,0038), destacando-se pela consistência dos resultados. Em contraste, a Bi-LSTM apresentou desempenho inferior, com acurácia média de 74,10%, e baixo desvio padrão (0,1466) e *loss* médio elevado (0,8740).

Tabela 5. Comparativo de Desempenho dos Modelos de RNN - Experimento 2

Arquitetura	Acurácia Média $\pm$ Desvio Padrão (%)	Loss Médio	F1-score
LSTM	98,92 $\pm$ 0,0038	0,0545	0,990
Bi-LSTM	74,10 $\pm$ 0,1466	0,8740	0,741
GRU	99,25 $\pm$ 0,0030	0,0475	0,990

A matriz de confusão apresentada na Tabela 6, evidencia que a LSTM manteve uma classificação quase perfeita, com a maioria das classes sendo identificadas com 100% de precisão e apenas mínimas confusões entre “Buraco B” e “Normal”, e entre “Normal” e “Tachões”.

Tabela 6. Matriz de Confusão Normalizada LSTM - Experimento 2

Previsto \ Real	Quebra-molas	Buraco A	Buraco B	Lombofaixa	Tachões	Normal
Quebra-molas	1,00	0,00	0,00	0,00	0,00	0,00
Buraco A	0,00	1,00	0,00	0,00	0,00	0,00
Buraco B	0,00	0,01	0,96	0,00	0,00	0,03
Lombofaixa	0,00	0,01	0,00	0,99	0,00	0,00
Tachões	0,00	0,00	0,00	0,00	1,00	0,00
Normal	0,00	0,00	0,00	0,00	0,06	0,94

Em seguida, a Tabela 7 mostra que a Bi-LSTM teve desempenho inferior ao do Experimento 1, apresentando maior dificuldade em distinguir as classes. Observam-se

confusões entre classes similares, como 5% de “Buraco A” classificados como “Buraco B”, 4% de “Buraco B” como “Buraco A”, 6% de “Normal” como “Quebra-molas”, 4% de “Quebra-molas” como “Lombofaixa” e 3% de “Lombofaixa” como “Buraco A”.

Tabela 7. Matriz de Confusão Normalizada Bi-LSTM - Experimento 2

Previsto \ Real	Quebra-molas	Buraco A	Buraco B	Lombofaixa	Tachões	Normal
Quebra-molas	0,93	0,00	0,00	0,04	0,00	0,03
Buraco A	0,00	0,95	0,05	0,00	0,00	0,00
Buraco B	0,00	0,04	0,93	0,00	0,00	0,04
Lombofaixa	0,03	0,02	0,01	0,92	0,00	0,02
Tachões	0,01	0,03	0,01	0,05	0,90	0,00
Normal	0,06	0,00	0,00	0,00	0,00	0,94

Por fim, a Tabela 8 mostra que a GRU obteve um desempenho notável no Experimento 2. Os valores da diagonal principal foram elevados em todas as classes e poucas confusões observadas ocorreram, como em “Buraco B”, com 1% classificado como “Buraco A”, em “Lombofaixa”, com 1% identificado como “Buraco B”, e em “Normal”, com 3% classificado incorretamente como “Lombofaixa”. Apesar dessas pequenas imprecisões, o modelo demonstrou ser consistente e obteve resultados superiores em relação às demais arquiteturas avaliadas.

Tabela 8. Matriz Normalizada GRU - Experimento 2

Previsto \ Real	Quebra-molas	Buraco A	Buraco B	Lombofaixa	Tachões	Normal
Quebra-molas	1,00	0,00	0,00	0,00	0,00	0,00
Buraco A	0,00	1,00	0,00	0,00	0,00	0,00
Buraco B	0,00	0,01	0,99	0,00	0,00	0,00
Lombofaixa	0,00	0,00	0,01	0,99	0,00	0,00
Tachões	0,00	0,00	0,00	0,00	1,00	0,00
Normal	0,00	0,00	0,00	0,03	0,00	0,97

5. Conclusões

A comparação dos modelos nos dois experimentos mostrou que a GRU obteve os melhores resultados na classificação entre as classes analisadas. No Experimento 1, a GRU alcançou acurácia média de 98,61% com baixo desvio padrão (0,0036), seguida de perto pela LSTM com 98,21% e Bi-LSTM com 97,98%. Já no Experimento 2, a GRU manteve a acurácia alta (99,25%) e baixo desvio padrão (0,0030), a LSTM obteve um desempenho superior comparado ao Experimento 1 (98,92%), enquanto a Bi-LSTM apresentou queda significativa (74,10%). Esses resultados evidenciam a eficácia da detecção de anomalias e a viabilidade da abordagem, que combina modelos RNN com uma plataforma hardware de baixo custo, apresentando desempenho consistente.

Apesar de possibilitar a coleta de dados, o ambiente experimental apresenta limitações, não contemplando fatores típicos de vias reais além dos obstáculos em pequena escala, como variações de pavimento, vibrações e tráfego. Por isso, testes em campo são necessários para validar a robustez, a generalização e a aplicabilidade do modelo em condições reais.

Um sistema aprimorado baseado nesta pesquisa poderia ser usado para mapeamento viário, contribuindo para manutenção preventiva e segurança de motoristas e

pedestres. A detecção de irregularidades em tempo real é essencial para sistemas de navegação avançados, veículos autônomos e para a gestão de infraestruturas urbanas. Apesar das limitações do ambiente experimental, esta pesquisa abre caminho para futuras implementações em escala real.

6. Agradecimentos

Os autores agradecem ao Instituto Federal do Espírito Santo (IFES) pelo apoio institucional, por meio do auxílio a material de consumo concedido pelo Edital nº 10/2024 (Programa Prociência), que viabilizou o desenvolvimento deste projeto. Em especial, a autora Allicia R. dos Santos agradece ao IFES pela concessão da bolsa de Iniciação Científica vinculada ao Programa PICTI (Edital PRPPG nº 03/2024).

Referências

- Cho, K., Gulcehre, C., Bougares, F., Schwenk, H., and Bengio, Y. (2014). Learning phrase representations using rnn encoder-decoder for statistical machine translation. *arXiv preprint arXiv:1406.1078*.
- Confederação Nacional do Transporte (2024). *Pesquisa CNT de Rodovias 2024*. CNT; SEST SENAT; ITL, Brasília. ISBN 978-85-68865-23-1.
- De Zoysa, K., Keppitiyagama, C., and Weerathunga, S. (2007). A public transport system based sensor network for road surface condition monitoring. page 9.
- Eriksson, J., Girod, L., Hull, B., Newton, R., Madden, S., and Balakrishnan, H. (2008). The pothole patrol: Using a mobile sensor network for road surface monitoring. In *Proceedings of the 6th International Conference on Mobile Systems, Applications, and Services (MobiSys '08)*.
- Hochreiter, S. and Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8):1735–1780.
- Mednis, A., Strazdins, G., Zviedris, R., Kanonirs, G., and Selavo, L. (2011). Real time pothole detection using android smartphones with accelerometers. pages 1 – 6.
- Rodas, Q. (2018). Novas tecnologias: carros atuais têm até 100 sensores a bordo. *Revista Quatro Rodas*. Acesso em: 8 ago. 2025.
- Rosca, C., Stancu, A., and Gortoescu, I.-A. (2025). Advanced sensor integration and ai architectures for next-generation traffic navigation. *Applied Sciences*, 15:4301.
- Schuster, M. and Paliwal, K. K. (1997). Bidirectional recurrent neural networks. *IEEE Transactions on Signal Processing*, 45(11):2673–2681.
- Ye, Z., Wei, Y., Yang, S., Li, P., Yang, F., Yang, B., and Wang, L. (2024). Iot-enhanced smart road infrastructure systems for comprehensive real-time monitoring. *Internet of Things and Cyber-Physical Systems*, 4:235–249.
- Zareei, M., Castañeda, C. A. L., Alanazi, F., Granda, F., and Díaz, J. A. P. (2025). Machine learning model for road anomaly detection using smartphone accelerometer data. *IEEE Access*, pages 1–1.